Part 1: Theretical Exercises

Analytical solution to linear regression

x	y
1180	221,900
2570	538,000
770	180,000
1960	604,000
1680	510,000

x= sqft_living , y= price

1.

$$X = \begin{bmatrix} 1 & 1180 \\ 1 & 2570 \\ 1 & 770 \\ 1 & 1960 \\ 1 & 1680 \end{bmatrix} \qquad y = \begin{bmatrix} 221,900 \\ 538,000 \\ 180,000 \\ 604,000 \\ 510,000 \end{bmatrix}$$

2. נעדכן בקוד של מת לחשב את הקלט מהחישובים - נעדכן ב קוב: helper.py-שם

נשים לב: $X^+ = (X^TX)^{-1}X^T$

• תחילה נחשב את X^T:

• כעת נחשב את X^TX:

$$X^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1180 & 2570 & 770 & 1960 & 1680 \end{bmatrix}$$

$$X^TX = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1180 & 2570 & 770 & 1960 & 1680 \end{bmatrix} \begin{bmatrix} 1 & 1180 \\ 1 & 2570 \\ 1 & 770 \\ 1 & 1960 \\ 1 & 1680 \end{bmatrix} = \begin{bmatrix} 5 & 8160 \\ 8160 & 15254200 \end{bmatrix}$$

• כעת נחשב את $(X^TX)^{-1}$

$$(X^TX)^{-1} = \frac{1}{\det(A)} \cdot \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \frac{1}{ad-bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \frac{1}{9,685,400} \begin{bmatrix} 15254200 & -8160 \\ -8160 & 5 \end{bmatrix}$$

• נעבור ל $(X^TX)^{-1}X^T$

$$(X^TX)^{-1}X^T = \frac{1}{9,685,400} \begin{bmatrix} 15254200 & -8160 \\ -8160 & 5 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1180 & 2570 & 770 & 1960 & 1680 \end{bmatrix} =$$

$$\frac{1}{9,685,400} \begin{bmatrix} 5625400 & -5717000 & 8971000 & -739400 & 1545400 \\ -2260 & 4690 & -4130 & 1640 & 240 \end{bmatrix} =$$

• כלומר

$$X^+ = (X^TX)^{-1}X^T = \frac{1}{9,685,400} \begin{bmatrix} 5625400 & -5717000 & 8971000 & -739400 & 1545400 \\ -2260 & 4690 & -4130 & 1640 & 240 \end{bmatrix} =$$

בשלב 2-4 נעדכן
בקוב פיתון - נעדכן
מה תוכן בשם
part1_helper.py

3. נשתמש בנוסחה: $w^* = X^+ y$

$$w^* = X^+ y = \frac{1}{9{,}685{,}400}\begin{bmatrix} 5625400 & -5717000 & 8971000 & -739400 & 1545400 \\ -2260 & 4690 & -4130 & 1640 & 240 \end{bmatrix}\begin{bmatrix} 221900 \\ 538{,}000 \\ 180{,}000 \\ 604{,}000 \\ 510{,}000 \end{bmatrix} = \begin{bmatrix} 13305.24913788 \\ 243.55070579 \end{bmatrix} = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}$$

4. נחשב את פונקציית ה loss: $J(w) = \|Xw - y\|_2^2$ עבור w^* כלומר $J(w^*) = \|Xw^* - y\|_2^2$

נשאלה קודמת קיבלנו:

$$w^* = \begin{bmatrix} 13305.25 \\ 243.55 \end{bmatrix}$$

• עתה נחשב את Xw^*: את ה values predicted

$$Xw^* = \begin{bmatrix} 300695.08 \\ 639230.56 \\ 200839.29 \\ 490664.63 \\ 422470.43 \end{bmatrix}$$

• עתה נחשב את $Xw^* - y$: כלומר את נקודת השאלה:

$$Xw^* - y = \begin{bmatrix} 300695.08 \\ 639230.56 \\ 200839.29 \\ 490664.63 \\ 422470.4 \end{bmatrix} - \begin{bmatrix} 221900 \\ 538{,}000 \\ 180{,}000 \\ 604{,}000 \\ 510{,}000 \end{bmatrix} = \begin{bmatrix} 78795.08 \\ 101230.56 \\ 20839.29 \\ -113335.37 \\ -87529.57 \end{bmatrix}$$

• עתה, נחשב את $(Xw^* - y)^2$:

$$(Xw^* - y)^2 = \begin{bmatrix} 6208664829.67 \\ 10247626597.86 \\ 434276095.58 \\ 12844905795.58 \\ 7661424931.05 \end{bmatrix}$$

* עתה, נחבר את כל רכיבי השגיאות:

$$J(w^*) = 6208664829.67 + 10247626597.86 + 434276095.58 + 12844905795.58 + 7661424931.05 = 37396898249.74$$

5. נרצה להראות ש $J(w)$ הוא פולינום מדרגה 2 ב w_0, w_1 ולמצוא את המקדמים a_0, a_1, b, c_0, c_1, d כך ש:

$$J(w) = a_0 w_0^2 + a_1 w_1^2 + b w_0 w_1 + c_0 w_0 + c_1 w_1 + d$$

לפי הגדרה: $J(w) = \sum_{i=1}^{5} (x^T x^{(i)} - y_i)^2$

מהגדרה שלנו:

$$x^1 = \begin{bmatrix} 1 \\ 1180 \end{bmatrix}, \quad x^2 = \begin{bmatrix} 1 \\ 2570 \end{bmatrix}, \quad x^3 = \begin{bmatrix} 1 \\ 770 \end{bmatrix}, \quad x^4 = \begin{bmatrix} 1 \\ 1960 \end{bmatrix}, \quad x^5 = \begin{bmatrix} 1 \\ 1680 \end{bmatrix}$$

$$y_1 = 221900 \quad y_2 = 538000 \quad y_3 = 180000 \quad y_4 = 604000 \quad y_5 = 510000$$

כך שנקבל:

$$J(w)=(w_0+1180w_1-221900)^2+(w_0+2570w_1-538000)^2+(w_0+770w_1-180,000)^2+(w_0+1960w_1-604000)^2+(w_0+1680w_1-510000)^2$$

• כעת נפתח אחר כל $(w_0+x_iw_1-y_i)^2$ לפי נוסחת הכפל המקוצר $(a+b+c)^2=a^2+b^2+c^2+2ab+2ac+2bc$ ונקבל:

$$(w_0+x_iw_1-y_i)^2=w_0^2+x_i^2w_1^2+y_i^2+2x_iw_0w_1-2y_iw_0-2x_iy_iw_1$$

• כעת נכנס אל כל i מתוך $1\le i\le 5$:

$$J(w)=\left(\sum_{i=1}^{5}1\right)w_0^2+\left(\sum_{i=1}^{5}x_i^2\right)w_1^2+\left(2\sum_{i=1}^{5}x_i\right)w_0w_1-\left(2\sum_{i=1}^{5}y_i\right)w_0-\left(2\sum_{i=1}^{5}x_iy_i\right)w_1+\sum_{i=1}^{5}y_i^2$$

• כעת נחשב כל מקדם:

(i) המקדם של w_0^2: $a_0=5$

(ii) המקדם של w_1^2: $a_1=1180^2+2570^2+770^2+1960^2+1680^2=15254200$

(iii) המקדם של w_1w_0: $b=2(1180+2570+770+1960+1680)=8160=16320$

(iv) המקדם של w_0: $c_0=-2(221900+538000+180000+604000+510000)=-2\cdot2053900=4107800$

(v) המקדם של w_1:

$$c_1=-2(1180\cdot\underset{2618420000}{221900}+2570\cdot\underset{1382660000}{538000}+770\cdot\underset{1386000000}{180000}+1960\cdot\underset{1183840000}{604000}+1680\cdot\underset{857800000}{510000})=-2\cdot38237420000=-76474840000$$

(vi) הביטוי הקבוע d:

$$d=49239610000+28944400000+3420000000+36481600000+26010000000=99599996100000$$

• ומשוון נקבל: $J(w)=5w_0^2+15254200w_1^2+16320w_0w_1-4107800w_0-76474840000w_1+99599996100000$

לכן ה $J(w)$ הוא פונקציה ממעלה 2 - כי הנקבה המרבית שלו היא 2.

6. בשאלה הקודמת קיבלנו את: $J(w)=5w_0^2+15254200w_1^2+16320w_0w_1-4107800w_0-76474840000w_1+99599996100000$

כעת נחשב את הנגזרות החלקיות של $J(w)$ לפי w_0 ו w_1 ונשווה לאפס את

$$\nabla J(w)=\left(\frac{\partial J}{\partial w_0},\frac{\partial J}{\partial w_1}\right)=(0,0)$$

• בשלב נחשב את הנגזרת החלקית לפי w_0 ו w_1:

$$\frac{\partial J}{\partial w_0}=10w_0+16320w_1-4107800 \qquad \frac{\partial J}{\partial w_1}=30508400w_1+16320w_0-76474840000$$

• כעת נשווה ל 0 ונפתור משוואה זאת עם 2 נעלמים:

$$\begin{cases}10w_0+16320w_1-4107800=0\\30508400w_1+16320w_0-76474840000=0\end{cases}$$

$$\downarrow$$

$$\begin{cases}10w_0+16320w_1=4107800\\30508400w_1+16320w_0=76474840000\end{cases}$$

$$\downarrow$$

$$w_0=\frac{4107800-16320w_1}{10}$$

נציב את w_0 במשוואה השנייה:

$$16320\left(\frac{4107800-16320w_0}{10}\right)+30508400w_1=76474840000$$

$$6703929600-26634240w_1+30508400w_1=76474840000$$

$$6703929600+3874160w_1=76474840000$$

$$3874160w_1=94355540$$

$$w_1=\frac{94355540}{3874160}\approx243.55$$

כעת נציב במשוואה של w_0:

$$w_0 = \frac{4107800 - 16320 \cdot 243.55}{10} \approx 13305.25$$

ולכן קיבלנו כמסלול:

$$w = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} 13305.25 \\ 243.55 \end{bmatrix}$$

Part 2: L1-regularized linear regression

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^{n} \quad , x^{(i)} \in \mathbb{R}^p \quad , \lambda \geq 0$$

index	x_1	x_2	y
1	1	2	3
2	2	0	1
3	3	1	4
4	0	-1	-1
5	-1	0	3

$$J_\lambda(w;D) \triangleq \frac{1}{n} \sum_{i=1}^{n} \left(w_0 + \sum_{j=1}^{n} w_j x_j^{(i)} - y^{(i)}\right)^2 + \lambda \sum_{j=0}^{p} |w_j|$$

$$X = \begin{pmatrix} 1 & 1 & 2 \\ 1 & 2 & 0 \\ 1 & 3 & 1 \\ 1 & 0 & -1 \\ 1 & -1 & 0 \end{pmatrix} \qquad y = \begin{pmatrix} 3 \\ 1 \\ 4 \\ -1 \\ 3 \end{pmatrix} \qquad w = \begin{pmatrix} w_0 \\ w_1 \\ w_2 \end{pmatrix}$$

1. $w_0 = 1$ bias column

2. gradient = הנגזרת שמאפסת min

=> נקבל gradient עבור הלוס $J_\lambda(w;D)$

שלב 1: $\frac{1}{n}\|Xw - y\|^2$:

$$\|Xw - y\|^2 = (Xw - y)^T (Xw - y) = w^T X^T X w - 2y^T X w + y^T y$$

$$\rightsquigarrow \nabla_w (w^T X^T X w) = 2X^T X w \quad \text{quadric}$$
$$\nabla_w (-2y^T X w) = -2X^T y \quad \text{linear}$$
$$\nabla_w (y^T y) = 0 \quad \text{constant}$$

$$\Downarrow$$

$$\nabla_w \left(\frac{1}{n} \|Xw - y\|^2\right) = \frac{1}{n}(2X^T X w - 2X^T y) = \frac{1}{n}(2X^T(Xw - y)) =$$
$$= \frac{2}{n} X^T (Xw - y)$$

- $v = \begin{pmatrix} v_1 \\ \vdots \\ v_p \end{pmatrix} \rightsquigarrow$ • $\|v\| = \sqrt{v_1^2 + \ldots + v_p^2}$
- $\|v\|^2 = v_1^2 + \ldots + v_p^2$
- $\|w\|_1 = |w_0| + |w_1| + |w_2|$

שלב 2: $\lambda \|w\|_1$:

- $\lambda \|w\|_1 = \lambda(|w_0| + |w_1| + |w_2|)$
- $w = \begin{pmatrix} w_0 \\ w_1 \\ w_2 \end{pmatrix}^*$ $\quad \lambda \sum_{j=1}^{3} |w_j|$

המשך ↓

$$|w_j| = \begin{cases} w_j & \text{if } w_j > 0 \\ -w_j & \text{if } w_j < 0 \end{cases} \Rightarrow \frac{\partial |w_j|}{\partial w_j} = \text{sign}(w_j)$$

* שוונ' סימן ב w_j כאפס לא מוגדר

$$\Rightarrow \frac{\partial}{\partial w_0} \lambda(|w_0| + |w_1| + |w_2|) = \lambda \cdot \text{sign}(w_0)$$

$$\frac{\partial}{\partial w_1} \lambda(|w_0| + |w_1| + |w_2|) = \lambda \cdot \text{sign}(w_1)$$

$$\frac{\partial}{\partial w_2} \lambda(|w_0| + |w_1| + |w_2|) = \lambda \cdot \text{sign}(w_2)$$

$$\Rightarrow \nabla_w (\lambda \|w\|_1) = \lambda \begin{pmatrix} \text{sign}(w_0) \\ \text{sign}(w_1) \\ \text{sign}(w_2) \end{pmatrix} = \lambda \cdot \text{sign}(w)$$

$$\nabla_w \bar{J}_\lambda(w;D) = \underbrace{\frac{2}{n} X^T(Xw - y)}_{1} + \underbrace{\lambda \cdot \text{sign}(w)}_{2}$$

$\boxed{\text{קיבלנו שלמה 2+1:}}$

$$w = \begin{pmatrix} 1 \\ -2 \\ 3 \end{pmatrix} \begin{matrix} w_0 \\ w_1 \\ w_2 \end{matrix}$$

η = learning rate ; too small: slow, more efficient
too big: fast, less efficient
right: reaches efficiency

.3

gradient descent algorithm $\quad w^{(t+1)} = w^t - \eta \cdot \nabla \bar{J}_\lambda(w^{(t)})$

$\eta = 0.1$, $n = 5$, $\lambda = 1$

$$= w^t - \eta \cdot \underbrace{\frac{2}{n} X^T(Xw - y) + \lambda \cdot \text{sign}\, w}_{2\ \text{אפס}}$$

$\boxed{\text{Iteration 1:}}$ $w^1 = w^0 - 0.1 \cdot \nabla \bar{J}_\lambda(w;D)$

$$X = \begin{pmatrix} 1 & 1 & 2 \\ 1 & 2 & 0 \\ 1 & 3 & 1 \\ 1 & 0 & -1 \\ 1 & -1 & 0 \end{pmatrix} \quad y = \begin{pmatrix} 3 \\ 1 \\ 4 \\ -1 \\ 3 \end{pmatrix} \quad w^0 = \begin{pmatrix} 1 \\ -2 \\ 3 \end{pmatrix} \rightsquigarrow$$

$$\cdot\ Xw_0 = \begin{matrix} \text{row} \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{matrix} \begin{matrix} 1\cdot 1 + 1\cdot(-2) + 2\cdot 3 \\ 1\cdot 1 + 2\cdot(-2) + 0\cdot 3 \\ 1\cdot 1 + 3\cdot(-2) + 1\cdot 3 \\ 1\cdot 1 + 0\cdot(-2) + (-1)\cdot 3 \\ 1\cdot 1 + (-1)\cdot(-2) + 0\cdot 3 \end{matrix} = \begin{pmatrix} 5 \\ -3 \\ -2 \\ -2 \\ 3 \end{pmatrix}$$

$$\cdot\ Xw_0 - y = \begin{pmatrix} 5 \\ -3 \\ -2 \\ -2 \\ 3 \end{pmatrix} - \begin{pmatrix} 3 \\ 1 \\ 4 \\ -1 \\ 3 \end{pmatrix} = \begin{pmatrix} 2 \\ -4 \\ -6 \\ -1 \\ 0 \end{pmatrix}$$

$$\cdot\ X^T = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 0 & -1 \\ 2 & 0 & 1 & -1 & 0 \end{pmatrix}$$

$$\cdot\ X^T(Xw_0 - y) = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 0 & -1 \\ 2 & 0 & 1 & -1 & 0 \end{pmatrix} \begin{pmatrix} 2 \\ -4 \\ -6 \\ -1 \\ 0 \end{pmatrix} = \begin{pmatrix} -9 \\ -24 \\ -1 \end{pmatrix}$$

$$\cdot\ \frac{2}{n} X^T(Xw - y) = \frac{2}{5} \cdot \begin{pmatrix} -9 \\ -24 \\ -1 \end{pmatrix} = \begin{pmatrix} -3.6 \\ -9.6 \\ -0.4 \end{pmatrix}$$

* $w_0 = 1 \rightsquigarrow \text{sign}(w_0) = +$
$w_1 = -2 \rightsquigarrow \text{sign}(w_1) = -$
$w_2 = 3 \rightsquigarrow \text{sign}(w_2) = +$

$$\Rightarrow \cdot\ \lambda \cdot \text{sign}\, w \quad 1 \cdot \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix}$$

המשך ↓

$$\cdot\ \frac{2}{n} X^T (Xw - y) + \lambda \cdot \operatorname{sign} w = \begin{pmatrix} -3.6 \\ -9.6 \\ -0.4 \end{pmatrix} + \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} = \begin{pmatrix} -2.6 \\ -10.6 \\ 0.6 \end{pmatrix}$$

$$\Rightarrow \quad w^1 = \begin{pmatrix} 1 \\ -2 \\ 3 \end{pmatrix} - 0.1 \cdot \begin{pmatrix} -2.6 \\ -10.6 \\ 0.6 \end{pmatrix} = \begin{pmatrix} 1.26 \\ -0.94 \\ 2.94 \end{pmatrix}$$

iteration 2: $w^2 = w^1 - 0.1 \cdot \nabla \bar{J}_\lambda(w, D)$

$$\cdot\ Xw_1 = \begin{array}{c} \text{Row} \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{array} \begin{array}{ccccc} 1 \cdot 1.26 + & 1 \cdot (-0.94) & + & 2 \cdot 2.94 \\ 1 \cdot 1.26 + & 2 \cdot (-0.94) & + & 0 \cdot 2.94 \\ 1 \cdot 1.26 + & 3 \cdot (-0.94) & + & 1 \cdot 2.94 \\ 1 \cdot 1.26 + & 0 \cdot (-0.94) & + & (-1) \cdot 2.94 \\ 1 \cdot 1.26 + & (-1) \cdot (-0.94) & + & 0 \cdot 2.94 \end{array} = \begin{pmatrix} 6.2 \\ -0.62 \\ 1.38 \\ -1.68 \\ 2.2 \end{pmatrix}$$

$$\cdot\ Xw_1 - y = \begin{pmatrix} 6.2 \\ -0.62 \\ 1.38 \\ -1.68 \\ 2.2 \end{pmatrix} - \begin{pmatrix} 3 \\ 1 \\ 4 \\ -1 \\ 3 \end{pmatrix} = \begin{pmatrix} 3.2 \\ -1.62 \\ -2.62 \\ -0.68 \\ -0.8 \end{pmatrix}$$

$$\cdot\ X^T (Xw^1 - y) = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 0 & -1 \\ 2 & 0 & 1 & -1 & 0 \end{pmatrix} \begin{pmatrix} 3.2 \\ -1.62 \\ -2.62 \\ -0.68 \\ -0.8 \end{pmatrix} = \begin{pmatrix} -2.52 \\ -7.1 \\ 4.46 \end{pmatrix}$$

$$\cdot\ \frac{2}{n} X^T (Xw_1 - y) = \frac{2}{5} \cdot \begin{pmatrix} -2.52 \\ -7.1 \\ 4.46 \end{pmatrix} = \begin{pmatrix} -1.008 \\ -2.84 \\ 1.784 \end{pmatrix}$$

$$\cdot\ \frac{2}{n} X^T (Xw_1 - y) + \lambda \cdot \operatorname{sign}(w) = \begin{pmatrix} -1.008 \\ -2.84 \\ 1.784 \end{pmatrix} + \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1.008 \\ 2.84 \\ 1.784 \end{pmatrix}$$

$$w_2 = \begin{pmatrix} 1.26 \\ -0.94 \\ 2.94 \end{pmatrix} - 0.1 \cdot \begin{pmatrix} -1.008 \\ 2.84 \\ 1.784 \end{pmatrix} = \begin{pmatrix} 1.2608 \\ -0.556 \\ 2.66616 \end{pmatrix}$$

	w_0	w_1	w_2
$w^{(0)}$	1	-2	3
iteration1	1.26	-0.94	2.94
iteration2	1.2608	-0.556	2.66616

הבנו

המשך ↓

4. $w^* =$ אינטואיציה: $w^* = \frac{2}{n} X^T(Xw - y) + \lambda \, sign(w)$

$\tilde{w} =$ Pseudoinverse formula: $\tilde{w} = (X^T X)^{-1} X^T y$

<u>הוכחה</u>: $\bar{J}_\lambda(w^*; D) < \bar{J}_\lambda(\tilde{w}; D)$

w^* אינטואיטיבית כי- minimizer של $\bar{J}_\lambda(w; D)$, אם אינטואיציה איך לא weighted vector שיכול להיות רק אחד.

קיבלנו $\tilde{w} = (X^T X)^{-1} X^T y$ פותרת מינימום רק ל MSE בלי הוספת L1 penalty

אם גם w^* ו- $\tilde{w}$ אחוזיות ל LASSO full, w^* תהיה יחיד אם $\lambda > 0$.